

Sebastian Vintoñuke – 106063

Cindy Teresa Hsieh – 108051

Maria Delfina Cano Ros Langrehr – 109338

Lautaro Martin Sotelo – 107472

Toda afirmación que se realice debe estar apoyada en **evidencia**. Si se encuentra alguna **afirmación** que no está correctamente **fundamentada** con **evidencia**, se disminuirá la nota. Esto incluye las observaciones que realicen sobre el código y su funcionamiento en general. Que no existan métricas para un determinado QA no implica que no pueda evidenciarse el efecto de una táctica.

TODO: correr un corrector ortografico

1. SISTEMA RECIBIDO




Figura 1. Diagrama Components & Connectors del sistema base.

1.1. Arquitectura

El despliegue recibido sigue una arquitectura cliente-servidor. Nginx actúa como reverse proxy y deriva las solicitudes hacia una única instancia de la API de intercambio implementada con Node.js y Express. El despliegue también incluye Graphite/StatsD, Grafana y cAdvisor como componentes de observabilidad, aunque estos no forman parte de la lógica de negocio.

Dentro de la API existe una separación lógica en tres módulos: `app.js` expone la interfaz HTTP, `exchange.js` coordina las operaciones de cambio y `state.js` carga y persiste el estado. Esta separación es parcial: la lógica de negocio conserva referencias mutables a cuentas, tasas y logs, y modifica directamente dichas estructuras.

El archivo `docker-compose.yml` declara una sola instancia de la API y no configura réplicas, health checks ni una política de reinicio. Por lo tanto, una caída del proceso interrumpe el servicio hasta que un operador o una herramienta externa lo vuelva a iniciar. Además, la API es stateful: mantiene las cuentas, tasas y operaciones en memoria, por lo que agregar réplicas sin introducir un mecanismo de coordinación produciría estados divergentes.

La persistencia se realiza periódicamente sobre archivos JSON. Las cuentas y el log se escriben cada segundo, mientras que las tasas se escriben cada cinco segundos. En consecuencia, existe una ventana entre la modificación en memoria y su escritura en disco durante la cual una terminación abrupta puede provocar pérdida de datos. Esto no constituye un protocolo de consistencia eventual, sino una estrategia de durabilidad diferida sin garantías transaccionales.

1.2. Código

La separación de responsabilidades es incompleta. `exchange.js` calcula importes, coordina las llamadas al servicio de transferencias, valida el saldo interno, modifica las cuentas y registra el resultado. Esta concentración aumenta el acoplamiento y dificulta probar cada responsabilidad de forma aislada.

```
1 export async function exchange(exchangeRequest) {
2   ...
3   //get the exchange rate
4   const exchangeRate = rates[baseCurrency][counterCurrency];
5   //compute the requested (counter) amount
6   const counterAmount = baseAmount * exchangeRate;
7   ...
8   //all good, update balances
9   baseAccount.balance += baseAmount;
10  counterAccount.balance -= counterAmount;
11  ...
12 }
```

Código 1. app/exchange.js.

`state.js` no expone directamente sus variables internas, pero sus getters retornan las mismas referencias mutables almacenadas por el módulo. Luego de la inicialización, `exchange.js` conserva esas referencias y modifica los objetos sin pasar por una operación explícita del componente de persistencia. Por ello, la abstracción es permeable: reemplazar los JSON por un repositorio o una base de datos requeriría adaptar también la forma en que la lógica de negocio lee y actualiza el estado.

```

1 let accounts;
2 let rates;
3 let log;
4
5 export async function init() {
6   await stateInit();
7
8   accounts = stateAccounts();
9   rates = stateRates();
10  log = stateLog();
11 }

```

Código 2. app/exchange.js.

El endpoint `/exchange` también contiene una condición de carrera. La comprobación de saldo se ejecuta antes de dos operaciones asíncronas. Mientras una solicitud se encuentra suspendida en un `await`, otra puede comprobar el mismo saldo y aprobar la operación. Ambas solicitudes pueden completar los descuentos y dejar un saldo negativo. El Listado 3 muestra la sección crítica, que no está protegida por exclusión mutua, serialización ni una transacción.

```

1 // app/exchange.js (caso base)
2 if (counterAccount.balance >= counterAmount) {
3   if (await transfer(clientBaseAccountId, baseAccount.id, baseAmount)) {
4     if (
5       await transfer(counterAccount.id, clientCounterAccountId, counterAmount)
6     ) {
7       baseAccount.balance += baseAmount;
8       counterAccount.balance -= counterAmount;
9       exchangeResult.ok = true;
10      exchangeResult.counterAmount = counterAmount;
11    }
12  }
13 }

```

Código 3. Sección crítica de `app/exchange.js` en el caso base.

El registro de operaciones tampoco tiene una política de retención. Cada resultado se agrega a un arreglo en memoria y `/log` devuelve el arreglo completo. A medida que aumenta la cantidad de operaciones, crecen el consumo de memoria, el tamaño de la respuesta y el trabajo necesario para serializar el estado. Además, el arreglo completo se convierte a JSON y se reescribe cada segundo, por lo que el costo de cada persistencia aumenta con el historial.

```

1 // app/exchange.js (caso base)
2 log.push(exchangeResult);
3
4 // app/app.js (caso base)
5 app.get("/log", (req, res) => {
6   res.json(getLog());
7 });
8
9 // app/state.js (caso base)
10 scheduleSave(log, LOG, 1000);
11
12 function scheduleSave(data, fileName, period) {
13   setInterval(async () => {
14     await save(data, fileName);
15   }, period);
16 }

```

Código 4. Crecimiento y persistencia del log en el caso base.

La escritura utiliza directamente el archivo definitivo. No se escribe primero a un archivo temporal ni se realiza un reemplazo atómico, por lo que una interrupción durante `writeFile` puede dejar un JSON incompleto. El manejo de errores de `state.js` registra el fallo, pero no lo propaga ni permite que la API informe que el estado no pudo persistirse.

```

1 async function save(data, fileName) {
2   const filePath = path.join(__dirname, fileName);
3   try {
4     await fs.promises.writeFile(filePath, JSON.stringify(data, null, 2));
5   } catch (err) {
6     console.error(`Error writing to ${filePath}:`, err);

```

```

7   }
8 }

```

Código 5. app/state.js.

Los importes monetarios se representan mediante `Number`, cuyo formato de punto flotante binario no representa exactamente todos los valores decimales. Sin una regla explícita de redondeo o una representación en unidades mínimas, el error puede acumularse en los saldos y en los importes entregados al cliente.

```

1 const exchangeRate = rates[baseCurrency][counterCurrency];
2 //compute the requested (counter) amount
3 const counterAmount = baseAmount * exchangeRate;

```

Código 6. Cálculo monetario con `Number` en app/exchange.js.

Finalmente, las validaciones HTTP comprueban únicamente la presencia mediante condiciones de truthiness. No se validan tipos, rangos, monedas soportadas ni coherencia entre moneda y cuenta. Por ejemplo, un importe negativo supera la validación inicial y puede alterar los saldos en el sentido contrario al esperado. Las monedas inexistentes también pueden producir excepciones al acceder a una tasa o cuenta no encontrada. A su vez, los rechazos de negocio se informan como HTTP 500, aunque no necesariamente representan una falla interna del servidor.

```

1 // app/app.js (caso base)
2 if (
3   !baseCurrency ||
4   !counterCurrency ||
5   !baseAccountId ||
6   !counterAccountId ||
7   !baseAmount
8 ) {
9   return res.status(400).json({ error: "Malformed request" });
10 }

```

Código 7. Validación por presencia en app/app.js.**Cuadro 1.** Hallazgos del análisis estático del caso base.

Hallazgo	Evidencia	QA afectados	Consecuencia posible	Validación propuesta
Carrera concurrente	La verificación de saldo precede a dos operaciones asíncronas y el descuento ocurre después (Listado 3).	Reliability, Security	Dos solicitudes pueden aprobarse con el mismo saldo y producir un balance negativo.	Ejecutar dos cambios concurrentes de 80 unidades contra un saldo interno de 100 y observar respuestas y saldo final.
Estado mutable expuesto	Los getters de <code>state.js</code> retornan objetos que <code>exchange.js</code> conserva y modifica.	Modificabilidad, Testability, Reliability	Las actualizaciones eluden una interfaz de repositorio y dificultan sustituir o simular la persistencia.	Probar la lógica con un repositorio simulado y registrar qué dependencias deben reemplazarse.
Log sin límite	Cada operación ejecuta <code>log.push</code> ; <code>/log</code> retorna el arreglo completo (Listado 4).	Performance, Scalability, Availability	Aumentan memoria, tamaño de respuesta y tiempo de serialización con cada operación.	Ejecutar lotes crecientes y medir memoria, bytes y latencia de <code>/log</code> .
Reescritura completa	<code>scheduleSave</code> serializa y escribe el log completo cada segundo.	Performance, Efficiency, Reliability	El costo de I/O crece con el historial y una interrupción puede dejar el archivo incompleto.	Medir tamaño, tiempo de escritura y actividad de I/O para distintos volúmenes de log.
Durabilidad diferida	Los cambios residen en memoria hasta el siguiente intervalo y la escritura no es atómica.	Reliability, Availability	Una terminación abrupta puede perder operaciones confirmadas o impedir cargar el JSON.	Terminar la API dentro de la ventana de persistencia, reiniciarla y comparar estado y log.
Dinero con <code>Number</code>	El importe se obtiene mediante <code>baseAmount * exchangeRate</code> sin redondeo explícito (Listado 6).	Reliability, Security	Pueden aparecer residuos decimales y acumularse diferencias en los saldos.	Utilizar valores como 0.1 y 0.2 y comparar contra un cálculo decimal exacto.
Validación incompleta	La API solo verifica truthiness y acepta valores negativos o combinaciones incoherentes (Listado 7).	Security, Reliability, Testability	Entradas inválidas pueden alterar saldos o provocar excepciones no controladas.	Crear casos con importes negativos, tipos incorrectos, monedas inexistentes y cuentas incompatibles.

1.3. Infraestructura

La infraestructura se define mediante Docker Compose. Nginx publica la API en el puerto 5555; Grafana, Graphite/StatsD y cAdvisor conforman el subsistema de observabilidad. La API no publica directamente su puerto al host, por lo que las pruebas externas deben atravesar Nginx, tal como requiere el enunciado.

El estado de la API se copia dentro de la imagen y no está asociado a un volumen. Por lo tanto, eliminar o recrear el contenedor descarta las modificaciones de sus archivos JSON. Grafana sí utiliza un volumen, mientras que Graphite no declara uno para conservar sus series. Estas decisiones limitan la durabilidad y la reproducibilidad de las mediciones entre recreaciones del entorno.

TODO: Agregar evidencia de ejecución sobre recuperación, persistencia y funcionamiento de cAdvisor en el equipo de pruebas.

2. ATRIBUTOS DE CALIDAD

2.1. Identificación de los QA claves

Se identifican los siguientes atributos de calidad como claves en el contexto del negocio. Adicionalmente, se citan especificaciones y requerimientos que motivaron estas afirmaciones.

2.1.1. Availability (disponibilidad)

Habilidad del sistema para reparar o enmascarar fallas de manera tal que el período fuera de servicio no exceda un determinado valor durante un lapso de tiempo especificado.

> La startup arVault es una fintech que opera una billetera digital, de reciente creación.

Al ser una billetera digital, el servicio permite manipular el dinero de los usuarios. Un servicio con baja o nula disponibilidad implicaría que los usuarios no pueden acceder a su propio dinero. Adicionalmente, el modelo de negocio se basa en que los usuarios operen, si el servicio no está disponible para permitir estas operaciones, se están perdiendo potenciales ganancias.

2.1.2. Performance

Habilidad del sistema para reaccionar ante ciertos eventos en un determinado tiempo.

> Si bien el lanzamiento fue exitoso, comenzaron a aparecer reclamos de los usuarios sobre problemas en el uso de la función de cambio de monedas.

Uno de los principales candidatos a explicar los reclamos es el endpoint /exchange. Una operación exitosa realiza dos transferencias secuenciales de entre 200 y 400 milisegundos cada una, por lo que su tiempo de respuesta esperado es mayor que el de los endpoints que solo consultan memoria. Esta hipótesis debe contrastarse con las pruebas de carga.

> las tasas de cambio no tienen gap entre el valor de compra y de venta.

La ausencia de gap significa que la compra y la venta utilizan la misma cotización; no implica por sí misma que la tasa se actualice en tiempo real. Sin embargo, una latencia elevada aumenta el tiempo entre la cotización y la finalización del cambio, y por ello incrementa el riesgo de operar con un valor que ya no represente las condiciones vigentes.

2.1.3. Scalability (escalabilidad)

Habilidad del sistema para incorporar recursos adicionales de manera efectiva. Efectividad = mejora medible de algún QA + no requerir un esfuerzo inapropiado + no interrumpir el funcionamiento.

> Para ganar usuarios, las tasas de cambio...

Se especifica que el objetivo a corto plazo es incrementar el número de usuarios. El sistema debe poder acompañar ese crecimiento incorporando recursos sin interrumpir el servicio ni exigir un esfuerzo inapropiado.

2.1.4. Reliability (confiabilidad)

Grado en que la arquitectura es susceptible a fallas a nivel de sistema cuando se producen fallas parciales en componentes, conectores o datos.

La confiabilidad es clave porque el servicio modifica saldos que representan dinero. Una respuesta exitosa con un saldo incorrecto constituye una falla aunque el proceso permanezca disponible. La condición de carrera y la persistencia diferida identificadas en la Sección 1.2 pueden producir pérdida de operaciones confirmadas, balances negativos o un estado distinto después de reiniciar el servicio.

2.1.5. Security (seguridad)

Capacidad del sistema de prevenir acciones maliciosas o accidentales fuera del uso esperado.

> No se valida que haya saldo en la cuenta del cliente, se espera que lo haga la UI y que no permita la operación.

Confiar en validaciones realizadas exclusivamente por el cliente permite que un consumidor invoque directamente la API con valores inesperados. Aunque el enunciado supone autenticación y autorización previas, esos mecanismos no sustituyen la validación de tipos, rangos e invariantes de negocio. Una operación inválida puede provocar pérdidas monetarias y reputacionales.

2.2. Otros QA menos relevantes

Además se mencionan otros QA que, aunque no resulten claves y por ende no sean una prioridad, son deseables, especialmente conforme el proyecto crezca.

2.2.1. *Modifiability (modificabilidad)*

Facilidad con la que el sistema puede adaptarse a cambios en sus requerimientos, tecnologías o entorno.

> No me gusta guardar todo en archivos .json, por ahora va, pero tendría que hacer algo distinto.

> Ver el tema del manejo de las cuentas, debería ser responsabilidad de otro servicio.

El propio README del servicio anticipa cambios concretos: reemplazar el almacenamiento en archivos (el fundador incluso propone migrar a Redis) y mover la gestión de cuentas a otro servicio. Además, el enunciado indica que los fondos se destinaron a agregar funcionalidad. La modificabilidad no resuelve los reclamos actuales de los usuarios, por lo que no la consideramos clave, pero determina el costo de aplicar las mejoras que sí lo son.

2.2.2. *Efficiency (eficiencia)*

Performance obtenida por recurso consumido.

> En docker-compose.yml tienen la solución tal como corre en el único servidor disponible al momento de comenzar el proyecto.

Al contar con un único servidor, los recursos que consume una funcionalidad quedan disponibles para el resto. Sin embargo, arVault acaba de recibir inversión y el problema que amenaza al negocio son los reclamos por el funcionamiento del cambio de monedas, no el costo de infraestructura. Por eso priorizamos la performance y la disponibilidad por sobre la eficiencia, aceptando consumir más recursos si eso las mejora (como hacen las propuestas de este trabajo).

2.2.3. *Testability (testeabilidad)*

Grado en que un componente o sistema de software permite ser probado para exhibir sus fallas; usualmente relacionado al esfuerzo necesario para llevar adelante las tareas de testing.

> los potenciales inversores se niegan a aportar más fondos si no se realiza una auditoría y se mejora el servicio.

Los usuarios no perciben directamente la testeabilidad, pero la auditoría exigida por los inversores requiere demostrar que el servicio se comporta correctamente. El repositorio no incluye pruebas automatizadas: el script test del package .json es el generado por defecto (.error: no test specified"). Sin pruebas, cada corrección de los problemas de confiabilidad identificados corre el riesgo de introducir regresiones.

2.2.4. *Manageability (manejabilidad)*

Define la facilidad de gestión y monitoreo del sistema por parte de sus administradores.

> Actualiza el saldo de una cuenta. No me gusta cómo está hecho esto, otro servicio debería ocuparse de esto (el que hace las transferencias?)

Las cuentas internas y las tasas se administran a través de endpoints HTTP expuestos junto con los de los clientes, y el servicio original no emite métricas propias: para este trabajo tuvimos que instrumentarlo. Dado que se trata de un servicio con una única instancia y pocos operadores, no la consideramos clave, pero su falta dificulta diagnosticar problemas como los que motivaron los reclamos.

2.2.5. *Simplicity (simplicidad)*

Facilidad con la que la arquitectura de un sistema puede ser entendida, razonada y explicada.

> Su fundador, un desarrollador aficionado y entusiasta [...] se concentró en implementar rápidamente (bajo la consigna *fake it until you make it*) un núcleo de servicios que le permitieran conseguir más fondos a través de inversores.

El sistema fue desarrollado por una sola persona sin experiencia profesional y priorizando la velocidad. Una arquitectura simple facilita que el equipo (que hoy incluye a arquitectos externos) la entienda y la modifique. No es un QA clave, pero toda táctica que se proponga debe justificar la complejidad que agrega.

2.3. Decisiones de diseño actuales y su impacto en los QA

A continuación recorreremos los QA, claves y no claves, analizando cómo los afectan las decisiones de diseño del sistema recibido. La evidencia proviene del análisis del código (Sección 1.2), de la infraestructura (Sección 1.3) y de las pruebas sobre el sistema base (Sección 3).

2.3.1. Impacto en la Disponibilidad

- **Instancia única sin política de reinicio ni health check.** El `docker-compose.yml` declara una sola instancia de la API sin `restart` ni `healthcheck`. Cualquier falla que termine el proceso deja el servicio fuera de línea de forma indefinida. En el escenario de caos, una única request inválida tiró la API en el minuto 3:15 y no volvió a completarse ninguna request durante el resto de la prueba (Figura 21).
- **Errores no controlados en handlers asíncronos.** El handler de `/exchange` es una función `async` sin `try/catch`. Express 4 no captura el rechazo de la promesa, y Node.js 24 (la versión de la imagen) termina el proceso ante un rechazo no manejado. Por eso una excepción aislada, como la de una moneda inexistente, afecta a todos los usuarios.
- **Log y operaciones de negocio en el mismo proceso.** La degradación de `/log` arrastra a `/exchange`: en el escenario de resistencia aparecen fallas a partir del minuto 20 aunque la carga es constante (Figura 15).

2.3.2. Impacto en la Performance

- **Estado en memoria (positivo).** Las lecturas de cuentas y tasas no acceden a disco: `GET /rates` responde en torno a 1 ms en P95 (Figura 5).
- **Transferencias secuenciales.** Cada cambio exitoso espera dos transferencias de entre 200 y 400 ms, una después de la otra, por lo que `/exchange` no puede responder en menos de 400 ms aun sin carga. Si fueran independientes podrían solaparse, pero la segunda depende del resultado de la primera.
- **Serialización síncrona de un log sin límite.** `/log` serializa el arreglo completo con `res.json`, operación síncrona que bloquea el event loop durante un tiempo proporcional al tamaño del log. A esto se suma la reescritura completa del archivo cada segundo. En el escenario de estrés, el CPU se satura y la latencia de `/exchange` comienza a crecer a partir del minuto 4 (Figuras 12 y 11).

2.3.3. Impacto en la Escalabilidad

- **Estado en memoria y en archivos locales.** Como se discutió en la Sección 1.1, agregar réplicas de la API produciría estados divergentes, por lo que el escalado horizontal no es posible sin mover el estado a un almacenamiento compartido.
- **Un único hilo de ejecución.** Node.js ejecuta el código de la aplicación en un solo hilo. En las pruebas de estrés y resistencia el CPU se satura en torno al 100 %, es decir un núcleo (Figuras 12 y 18), por lo que asignar más núcleos al contenedor no mejoraría la capacidad sin cambiar la arquitectura.
- **Costo creciente con el historial.** El costo de `/log` y de la persistencia crece con la cantidad de operaciones realizadas, de modo que más usuarios aceleran la degradación aunque la carga por segundo se mantenga.

2.3.4. Impacto en la Confiabilidad

- **Verificación de saldo sin exclusión mutua.** La condición de carrera del Listado 3 permite aprobar dos operaciones con el mismo saldo.
- **Durabilidad diferida y escritura no atómica.** Las operaciones confirmadas al cliente pueden perderse si el proceso termina antes del siguiente guardado, y una interrupción durante la escritura puede dejar el archivo corrupto (Listado 5).
- **Importes con Number.** El uso de punto flotante binario para dinero (Listado 6) puede acumular diferencias en los saldos.

2.3.5. Impacto en la Seguridad

- **Validación por presencia.** La API acepta importes negativos, tipos incorrectos y monedas inexistentes (Listado 7). Combinado con la falta de manejo de errores, una sola request malformada funciona como un ataque de denegación de servicio, como se evidencia en el escenario de caos.
- **Endpoints administrativos expuestos.** `/accounts/<id>/balance` y `PUT /rates` se publican a través del mismo `nginx` que los endpoints de los clientes. Si bien asumimos que el componente de autorización filtra quién puede invocarlos, la API no aplica ninguna defensa propia ni deja registro de estos cambios en el log.

2.3.6. Impacto en la Modificabilidad

- **Código reducido y dividido en tres módulos (positivo).** La separación entre `app.js`, `exchange.js` y `state.js` permite ubicar rápidamente cada responsabilidad.
- **Abstracción de persistencia permeable.** Los getters de `state.js` devuelven referencias mutables que `exchange.js` modifica directamente (Listado 2). Reemplazar los archivos por una base de datos, como pide el fundador, obliga a modificar también la lógica de negocio.
- **Concentración de responsabilidades en exchange.js** (Listado 1), que aumenta el acoplamiento entre cálculo, validación, transferencia y registro.

2.3.7. Impacto en la Testeabilidad

- **Estado global y dependencias fijas.** El estado se carga desde archivos al iniciar el módulo y el servicio de transferencias se invoca directamente, sin inyección de dependencias. Probar la lógica de cambio de forma aislada requiere preparar archivos reales y esperar los 200 a 400 ms de cada transferencia simulada.
- **Ausencia de pruebas automatizadas,** como se mencionó en la Sección 2.2.3.

2.3.8. Impacto en la Eficiencia

- **Persistencia periódica completa.** Las cuentas y el log se serializan y escriben completos cada segundo, aunque no haya habido cambios o solo se haya agregado una operación.
- **Log completo en memoria.** El uso de memoria crece durante toda la prueba de resistencia hasta un máximo de 22.5 % del límite del contenedor (Figura 18), sin que exista una política de retención.

2.3.9. Impacto en la Manejabilidad

- **Sin observabilidad propia.** El servicio recibido solo escribe mensajes en la consola; las métricas por endpoint y de volumen operado debieron agregarse para este trabajo (`endpoint_metrics.js` y `currency_metrics.js`). Como se vio en el escenario de caos, estas métricas se pierden cuando cae el proceso que las emite (Figura 23).
- **Estado dentro de la imagen.** El Dockerfile copia el directorio state en la imagen y no se declara un volumen (Sección 1.3), por lo que recrear el contenedor descarta el estado.
- **Configuración fija en el código.** El puerto y los períodos de persistencia no pueden ajustarse sin modificar el código y reconstruir la imagen.

2.3.10. Impacto en la Simplicidad

- **Un único proceso con almacenamiento en archivos (positivo).** El sistema completo puede entenderse leyendo tres archivos y levantarse con un solo contenedor, sin dependencias externas salvo el servicio de transferencias. Esta simplicidad es la que permitió construirlo rápidamente, y es también la causa de varias de las limitaciones anteriores.

2.4. Crítica

Las decisiones de diseño del sistema recibido son coherentes con el objetivo con el que fue construido: tener rápidamente un producto funcionando para conseguir inversores. Un único proceso con estado en memoria y persistencia en archivos es simple, fácil de desplegar y rápido para las consultas. Sin embargo, ese diseño se mantuvo cuando el servicio pasó a manejar dinero de usuarios reales, y los QA que sacrifican son precisamente los que identificamos como claves.

Los problemas más graves, en orden de impacto, son:

1. **Disponibilidad frágil:** una única request inválida deja el servicio fuera de línea de forma permanente, ya que se combinan la falta de validación, la falta de manejo de errores y la ausencia de cualquier mecanismo de recuperación.
2. **Degradación progresiva:** el log crece sin límite en el mismo proceso que atiende las operaciones de cambio, por lo que el servicio se degrada con el uso aunque la carga no aumente. Es la explicación más probable de los reclamos de los usuarios sobre la función de cambio.
3. **Correctitud de los saldos:** la condición de carrera, la durabilidad diferida y el uso de punto flotante comprometen la integridad del dinero de los usuarios, lo cual es inaceptable para una auditoría.

Las propuestas de este trabajo atacan los dos primeros puntos: la propuesta 1 (Sección 4) aísla el log de las operaciones de negocio y la propuesta 2 (Sección 5) agrega detección y recuperación de fallas. Los problemas de correctitud requieren cambios en la lógica de negocio (validación de entradas, exclusión mutua sobre los saldos, representación decimal del dinero y persistencia transaccional) que recomendamos como pasos siguientes, en particular al migrar el estado a una base de datos externa.

3. COMPORTAMIENTO DEL SERVICIO

3.1. Pruebas de carga

La prueba de carga se realizó usando una tasa constante de 40 usuarios durante 240s (4 minutos). Cada usuario realiza un solo request, es decir se mantiene un throughput constante de 40 requests por segundo. No se realizó warm-up ni ramp para no ensuciar las métricas de promedios. Tampoco se realizaron recargas de saldo intermedias, se utilizó una carga inicial suficiente para cubrir toda la prueba.

Adicionalmente, aprovechando que siendo este el sistema inicial no se plantea una comparativa, decidimos usarla para ilustrar el formato de los gráficos y explicar los criterios compartidos entre todos los escenarios.

Se pueden encontrar los resultados completos en el [Apéndice](#).




Figura 2. Para un primer diagnóstico del sistema se decidió utilizar todos los endpoints. Se asignaron 20 requests por segundo a /exchange por ser el endpoint principal en el contexto de negocio. Se asignaron 8 requests por segundo a /log por las hipótesis planteadas sobre su significativo impacto en la disponibilidad y latencia del sistema. Se asignaron 3 requests por segundo al resto de endpoints. Para todos los gráficos salvo se indique lo contrario el eje x muestra el tiempo transcurrido de la prueba y cada punto agrupa una ventana de 10 segundos. Adicionalmente en las leyendas de la derecha se muestran estadísticas relevantes al escenario, como por ejemplo el promedio, el último valor y/o el máximo.

3.1.1. Disponibilidad




Figura 3. Para evaluar la disponibilidad del sistema monitoreamos el estado de las requests. Completed indica cuántas requests finalizaron correctamente en la ventana de 10 segundos, mientras que Pending indica cuántas seguían en curso. En 4 minutos con una carga de 40 requests por segundo, se puede observar que el sistema no presentó inconvenientes.

3.1.2. Latencia




Figura 4. Para evaluar la latencia del sistema optamos por utilizar dos metodologías, la primera monitorear los tiempos de respuestas desde la perspectiva del cliente a través de Artillery. Optamos por realizar el monitoreo en P50, P95 y P99, sin embargo una consideración importante para esta metodología es que no distingue entre endpoints. Una consecuencia de esto último es por ejemplo los saltos en P50 donde dependiendo si la ventana contiene mayormente requests rápidas o del endpoint /exchange, la mediana se desplaza entre ambos grupos.




Figura 5. La siguiente metodología adoptada fue medir los tiempos de respuesta por endpoint desde la perspectiva del servidor. Se realizó agregando la recolección de métricas directamente en el servidor. Si bien en contraposición a la metodología anterior si podemos discernir entre endpoints, optamos por representar solo para P95 para no saturar la representación. Para el eje y optamos por una escala logarítmica por la gran discrepancia entre los tiempos. Una observación que veníamos anticipando es que los endpoints se agrupan en tres clases, /exchange lento por sus dependencias externas pero constante, /log que crece junto con el tamaño del propio log y los restantes los cuales son considerablemente más rápidos. En próximos escenarios nos vamos a limitar a monitorear un endpoint de cada grupo, es decir /exchange, /log y optamos por GET /rates como representante de los endpoints rápidos, de esta forma simplificar la representación.

3.1.3. Uso de recursos




Figura 6. Para evaluar el uso de recursos del sistema, monitoreamos el uso del CPU y de la memoria. El uso del CPU se lee sobre el eje y al lado izquierdo mientras que el uso de la memoria al lado derecho. Nuevamente, mantiene el formato de tiempo en el eje x con ventanas de 10 segundos. Una primera observación es que tanto el uso de CPU como el de memoria crece con el tiempo, se especula debido al crecimiento del log.

3.1.4. Volumen operado por moneda




Figura 7. Como la primera métrica de negocio, se evaluó el volumen operado por cada moneda. Para esto se agregó la recolección de métricas directamente en el servidor. Optamos por representar cada moneda con su respectivo valor en dólares, a la cotización vigente en cada operación, para que los valores sean comparables. Los volúmenes de diferentes monedas operados en un mismo punto se apilan para representar el total operado en ese punto. Se mantiene el formato de tiempo en el eje x pero se redujo la ventana a 1 segundo.

3.1.5. Volumen neto operado




Figura 8. Para la segunda métrica de negocio, se evaluó el volumen neto operado por cada moneda. Nuevamente, a través de la recolección de métricas directamente en el servidor. De igual modo, con cada moneda en su respectivo valor en dólares. A diferencia del volumen operado, las ventas se representan como valores negativos y las compras con valores positivos. Se mantiene el formato de tiempo en el eje x y la ventana de 1 segundo.

3.2. Pruebas de estrés

La prueba de estrés se realizó incrementando progresivamente la carga desde 40 hasta 180 en saltos de 20, cada salto con una duración de 45s, el tiempo total de la prueba es de 450s (7.5 minutos). Se realizó un warm-up inicial de 5 usuarios durante 30s. Además, al final de la prueba se dejó una instancia de recovery de nuevamente 5 usuarios esta vez durante 60s. Tampoco se realizaron recargas de saldo intermedias y se mantuvo el mismo uso de endpoints para que los resultados sean comparables.

Se pueden encontrar los resultados completos en el [Apéndice](#).

3.2.1. Disponibilidad




Figura 9. Se observa que el servidor bajo el crecimiento de la carga encuentra su punto de quiebre alrededor del minuto 4:30. A partir de ese momento, la disponibilidad del sistema se ve comprometida y se continúan completando solicitudes pero otras fallan.

3.2.2. Latencia




Figura 10. Se observa cómo previo a la pérdida de disponibilidad antes mencionada (4:30) el servidor ya empieza a presentar una degradación en los tiempos de respuesta desde el minuto 4.




Figura 11. Se observa cómo el crecimiento en los tiempos de respuesta de /log, dado por el crecimiento del log, impacta directamente en la latencia del endpoint /exchange.

3.2.3. Uso de recursos




Figura 12. Se observa que el cuello de botella del servidor es el CPU, ya que alcanza su máxima capacidad en el minuto 4, junto con el comienzo de la degradación del servidor. Igualmente aunque en menor medida la memoria también muestra signos de crecimiento. Ambos factores generados por el crecimiento del log, lo que aumenta el costo de serialización para el CPU y el uso de memoria para almacenar los datos.

3.2.4. Volumen operado por moneda




Figura 13. Se observa cómo se degrada el volumen operado a partir del minuto 4, esto implica potenciales pérdidas económicas tanto para usuarios como para la plataforma.

3.2.5. Volumen neto operado




Figura 14. Para el volumen neto, se observan los mismos resultados expuestos para el volumen operado por moneda.

3.3. Pruebas de resistencia

La prueba de resistencia se realizó usando una tasa constante de 40 usuarios durante 2700s (45 minutos). Se realizó un warm-up inicial de 5 usuarios durante 60s. Además, al final de la prueba se dejó una instancia de recovery de nuevamente 5 usuarios esta vez durante 120s (2 minutos). Tampoco se realizaron recargas de saldo intermedias y se mantuvo el mismo uso de endpoints para que los resultados sean comparables.

Se pueden encontrar los resultados completos en el Apéndice.

3.3.1. Disponibilidad




Figura 15. A diferencia del escenario de estrés, en este caso se observa que la pérdida de disponibilidad no es producto del aumento de la carga sino que también se produce la misma degradación bajo un escenario prolongado de carga continua. Las primeras requests fallidas empiezan a ocurrir posterior al minuto 20. A partir de ahí se observa un incremento sostenido en la cantidad de fallos hasta la fase de recuperación al final de la prueba.

3.3.2. Latencia




Figura 16. Se observa cómo nuevamente el aumento en la latencia desde la perspectiva del cliente es en el minuto 20, previo a la aparición de las primeras requests fallidas. Coherente con una degradación progresiva y no un error abrupto.




Figura 17. En cuanto a la latencia por endpoint se observan los mismos síntomas que los descritos en la prueba de estrés. El endpoint /log perjudica la latencia del endpoint /exchange conforme el tamaño del log aumenta y con este su tiempo de respuesta. Este comportamiento se evidencia a partir del minuto 20, consistente con las conclusiones de disponibilidad y latencia antes mencionadas.

3.3.3. Uso de recursos




Figura 18. Se observa un incremento en el uso de recursos, especialmente de CPU, alcanzando este el máximo disponible a los 20 minutos. El uso de memoria también siguió incrementando con respecto a las observaciones en las pruebas de carga, llegando hasta un máximo de 22.5 % de la memoria disponible.

3.3.4. Volumen operado por moneda




Figura 19. Se observa una degradación en el volumen operado a partir de los 20 minutos con respecto a los minutos previos.

3.3.5. Volumen neto operado




Figura 20. Se observa una tendencia similar en el volumen neto operado, con una disminución notable a partir de los 20 minutos.

3.4. Pruebas de caos

La prueba de caos se realizó usando una tasa constante de 40 usuarios durante 480s (8 minutos). El reparto de requests se mantiene igual que en la prueba de resistencia. Adicionalmente se agrega una request malintencionada sabiendo que no hay un buen manejo de errores. Este tiene una probabilidad suficiente para aparecer entre 2 o 3 veces a lo largo de la prueba. Cada usuario realiza un solo request, es decir se mantiene un throughput constante de 40 requests por segundo. No se realizó warm-up ni ramp porque no aportaban información relevante para esta prueba. Tampoco se realizaron recargas de saldo intermedias, se utilizó una carga inicial suficiente para cubrir toda la prueba.

Se pueden encontrar los resultados completos en el [Apéndice](#).

3.4.1. Disponibilidad




Figura 21. Se observa cómo el sistema cae cerca del minuto 3:15 en la primera request inválida. A partir de ese momento las requests no se completan y esperan un timeout completo de 10s. Se verifica que el sistema no se recupera como se mencionó en la Sección 1.1.

3.4.2. Latencia




Figura 22. Posterior a la caída se observa el aumento en los tiempos de respuesta siendo estas devueltas por nginx como errores 502 en lugar de por el propio servidor.




Figura 23. No se observan métricas posteriores al momento de la caída. Esto se debe a que el mecanismo para recolectar las métricas es parte del propio servidor y deja de funcionar cuando el servidor cae.

3.4.3. Uso de recursos




Figura 24. De igual manera, se dejan de reportar las métricas de uso de recursos posterior a la caída del servidor. Esto se debe a la caída del propio proceso.

3.4.4. Volumen operado por moneda




Figura 25. Posterior a la caída y como consecuencia de esta se deja de operar, el total se estanca en \$298K por moneda en 8 minutos.

3.4.5. Volumen neto operado




Figura 26. Análogamente, posterior a la caída y como consecuencia de esta se deja de operar y el volumen neto se estanca.

3.5. Resultados y conclusiones

Los resultados obtenidos del escenario de carga nos indican que podemos clasificar los endpoints en tres categorías lo que nos permitirá simplificar nuestro análisis. Adicionalmente, los resultados del escenario de estrés y resistencia nos indican que el sistema presenta una

degradación significativa por la mala gestión del log. Esta observación motivará la propuesta 1. Finalmente, los resultados del escenario de caos nos indican que el sistema base no provee mecanismos de recuperación. Esta observación motivará la propuesta 2.

4. PROPUESTA 1

El sistema presenta una degradación principalmente por el manejo indebido del log. Destacamos que la posibilidad de permitir consultar el log de manera completa es la principal causa de degradación. Este escala con el número de operación, lo que provoca un aumento en el uso de recursos para mantenerlo, y un aumento en los tiempos de respuesta para consultarlo. Esto arrastra la degradación a los otros endpoints, entre ellos /exchange, el principalmente mencionado por los usuarios.

Destacamos que un endpoint que permite consultarlo todo por definición no es escalable, recomendamos la implementación de paginación. Sin embargo, asumimos que este es un requerimiento de negocio y que las mejoras propuestas no deben alterar la firma del sistema para con los usuarios. Se propone desacoplar el log para que la degradación de este no afecte a los endpoints de negocio del sistema. Proponemos agregar un nodo dedicado, análogo a exchange-api para el manejo del log. Algunas optimizaciones de la implementación que consideramos que vale la pena mencionar son:

- Remplazamos el uso del formato .json para el almacenamiento a .ndjson, de esta manera podemos agregar los registros al final sin reescribir todo el archivo.
- El archivo ya no se carga en memoria, se streamea el cliente directamente desde disco en batches. Destacamos que agregamos los caracteres [al inicio y] al final del stream para mantener la firma original con respecto al formato .json.
- Solo enviamos hasta el último byte válido disponible al momento de recibida la consulta y verificamos que la última entrada sea válida (evita race condition con la escritura).
- Exchange api loguea directamente al nuevo nodo dedicado mediante una conexión TCP dedicada.




Figura 27. Diagrama Components & Connectors de la propuesta 1.

4.1. Impacto en los QA

4.1.1. Performance

Es el QA que la propuesta busca mejorar. Al mover el log a un nodo dedicado, la serialización y el envío del log completo dejan de ejecutarse en el mismo proceso (y el mismo event loop) que atiende /exchange, por lo que la latencia de las operaciones de negocio deja de depender del tamaño del log. Además, el nodo de logs ya no mantiene el log en memoria ni lo reescribe completo cada segundo: agrega cada registro al final del archivo y lo lee desde disco en streaming al ser consultado.

Como se verá en las pruebas de estrés, la latencia de /exchange se mantiene estable mientras /log se degrada (Figura 30). Por otro lado, la consulta del log sigue siendo $O(n)$ sobre la cantidad de operaciones, por lo que /log continúa degradándose con el tiempo, y los percentiles altos vistos desde el cliente empeoran al procesarse más operaciones.

4.1.2. Disponibilidad

La degradación del log ya no arrastra a los endpoints de negocio: en el escenario de resistencia el sistema base comenzaba a fallar a los 20 minutos, mientras que la propuesta 1 completó todas las requests durante los 45 minutos (Figura 34).

Sin embargo, se agrega una nueva dependencia en el arranque: la API de exchange no comienza a atender requests hasta conectarse con el nodo de logs, y reintenta indefinidamente cada 1 segundo. Si el nodo de logs no está disponible, la API tampoco lo está. Una vez iniciada, en cambio, una caída del nodo de logs no detiene a la API de exchange.

4.1.3. Confiabilidad

El nuevo formato mejora la persistencia del log: cada registro se agrega al final del archivo en lugar de reescribir el archivo completo cada segundo, lo que elimina la ventana en la que un fallo durante la escritura corrompía todo el log. La consulta solo envía hasta el último byte escrito al momento de recibirla y descarta una línea incompleta, por lo que el cliente siempre recibe un JSON válido.

Como contrapartida, el envío del registro es *fire and forget*: la API de exchange escribe en el socket TCP y responde al cliente sin esperar confirmación de que el registro fue persistido. Además, la conexión se establece una única vez en el arranque y no hay reconexión: si el nodo de logs se cae o se reinicia, las operaciones se siguen confirmando al cliente pero dejan de registrarse en el log sin ningún aviso. Para un log de transacciones de una fintech, que puede ser necesario para auditoría, esto es un riesgo que debe resolverse (por ejemplo, con reconexión y un buffer local, o confirmando la escritura antes de responder, a costa de latencia).

4.1.4. Escalabilidad

El desacoplamiento permite escalar de forma independiente la API de exchange y el nodo de logs según la carga de cada uno. Replicar el nodo de logs para atender más consultas requeriría que las réplicas compartan el archivo (por ejemplo, mediante un volumen) o un almacenamiento externo, ya que actualmente el archivo vive dentro del contenedor. La escritura sigue concentrada en un único nodo.

4.1.5. Seguridad

El puerto TCP 3002 del nodo de logs acepta registros de cualquier cliente dentro de la red de Docker, sin autenticación ni validación del contenido. Cualquier contenedor comprometido podría insertar registros falsos en el log de transacciones, lo que afecta su integridad. El puerto no se publica al host y nginx solo expone /log, por lo que el riesgo queda acotado a la red interna.

4.1.6. Modificabilidad

Se separan responsabilidades que antes estaban mezcladas en state.js: la API de exchange ya no conoce cómo se almacena ni cómo se consulta el log, lo que permitiría cambiar el almacenamiento (por ejemplo, a una base de datos) sin tocarla. La interfaz pública de /log se mantiene sin cambios para los clientes. En contrapartida, el protocolo entre ambos nodos (JSON delimitado por saltos de línea sobre TCP) es ad hoc, y los nombres de host y puertos están fijos en el código y en la configuración de nginx.

4.1.7. Costo y simplicidad

Se agrega un contenedor con los mismos límites de recursos que la API (1 CPU y 4 GB de memoria), lo que duplica los recursos reservados. Según las mediciones, la API de exchange queda prácticamente ociosa, con un 14.2 % de CPU en el escenario de estrés (Figura 31), por lo que sus límites podrían reducirse. La arquitectura suma un componente y un conector nuevo, así como un orden de arranque a respetar, aunque la complejidad agregada es menor que la de la propuesta 2.

4.2. Pruebas de carga

Las pruebas de carga comparten la misma configuración con el sistema base de tal forma que los resultados sean comparables, ver Pruebas de carga.

Se pueden encontrar los resultados completos en el Apéndice.

4.3. Pruebas de estrés

Las pruebas de estrés comparten la misma configuración con el sistema base de tal forma que los resultados sean comparables, ver Pruebas de estrés.

Se pueden encontrar los resultados completos en el Apéndice.

4.3.1. Disponibilidad




Figura 28. Comparativa de la disponibilidad ofrecida por la propuesta 1 (izquierda) y el sistema base (derecha) frente a un escenario de estrés. La propuesta 1 obtuvo un incremento en el promedio de respuestas satisfactorias de 225 respuestas adicionales, lo que representa un aumento del 33.23 % frente al caso base.

4.3.2. Latencia




Figura 29. Comparativa de los resultados de latencia entre la propuesta 1 (izquierda) y el sistema base (derecha) frente a un escenario de estrés. Se observa que la propuesta 1 mejoró el promedio de latencia para P50. También se observa que empeoró en P95 y P99.




Figura 30. Comparativa de los resultados de latencia por endpoint entre la propuesta 1 (izquierda) y el sistema base (derecha) frente a un escenario de estrés. Con diferencia el análisis más interesante, la propuesta 1 permitió como se esperaba mejorar la latencia en el endpoint /exchange, se puede notar que este no se ve afectado por la degradación del endpoint /log. Como sí ocurría en el caso base, donde alrededor del minuto 4, los tiempos de respuesta de /exchange incrementaban, en este caso, los tiempos de respuesta se mantienen estables en 1 segundo, acotado por la dependencia del servicio externo. Por otro lado, los tiempos de respuesta de /log empeoraron, sin embargo es esperable, la mayor disponibilidad antes mencionada implica que se registraron más transacciones, por lo que el tamaño del log necesariamente aumentó. Esto explica el aumento de los tiempos de respuesta visto desde el lado del cliente antes mencionados, sin embargo, las métricas se ven ensuciadas al mezclar todos los endpoints.

4.3.3. Uso de recursos




Figura 31. Comparativa de los resultados del uso de recursos entre la propuesta 1 (izquierda) y el sistema base (derecha) frente a un escenario de estrés. Destacar que consideramos la comparación con respecto a ambos nodos, el nodo de exchange y el de logs. Se puede observar que el nodo de logs mantiene la carga con respecto a la del sistema base, incluso la aumenta. Esto es esperable con el aumento de la disponibilidad, más requests completadas implican más entradas en el log. Sin embargo, el nodo de exchange apenas llegó a un 14.2 % de uso de CPU y 1.42 % de uso de memoria.

4.3.4. Volumen operado por moneda




Figura 32. Comparativa de los resultados de volumen operado en cada moneda entre la propuesta 1 (izquierda) y el sistema base (derecha) frente a un escenario de estrés. Se observa que la propuesta 1 obtuvo un mayor volumen total siendo este 1.58M frente al 1.18M del sistema base, es decir una mejora del 33.90 %.

4.3.5. Volumen neto operado




Figura 33. Comparativa de los resultados de volumen neto operado en cada moneda entre la propuesta 1 (izquierda) y el sistema base (derecha) frente a un escenario de estrés. Análogamente al volumen operado, se observa que el volumen neto también es mayor en la propuesta 1 frente al sistema base.

4.4. Pruebas de resistencia

Se pueden encontrar los resultados completos en el Apéndice.

4.4.1. Disponibilidad




Figura 34. Comparativa de la disponibilidad ofrecida por la propuesta 1 (izquierda) y el sistema base (derecha) frente a un escenario de resistencia. El sistema base mostraba una degradación crítica a los 20 minutos, mientras que la propuesta 1 logró completar satisfactoriamente todas las requests durante los 45 minutos.

4.4.2. Latencia




Figura 35. Comparativa de los resultados de latencia entre la propuesta 1 (izquierda) y el sistema base (derecha) frente a un escenario de resistencia. Consistente con los resultados de disponibilidad se muestra una gran mejora especialmente posterior al minuto 20. Sin embargo, la propuesta 1 sigue mostrando un principio de degradación a los 40 minutos, esperable dado el crecimiento del log.




Figura 36. Comparativa de los resultados de latencia por endpoint entre la propuesta 1 (izquierda) y el sistema base (derecha) frente a un escenario de resistencia. Para el tiempo de respuesta desde la perspectiva del servidor, se muestra cómo en la propuesta 1 los tiempos del endpoint /log ya no “empujan” los tiempos del endpoint /exchange, sin embargo como ya se mencionó, el endpoint /log continúa degradando. Los tiempos de respuesta de /log entre ambos casos lamentablemente no son comparables puesto que menor disponibilidad implica un menor crecimiento del propio log.

4.4.3. Uso de recursos




Figura 37. Comparativa de los resultados del uso de recursos entre la propuesta 1 (izquierda) y el sistema base (derecha) frente a un escenario de resistencia. Destacar que ambos casos no son directamente comparables, la propuesta 1 dispone de dos contenedores/nodos independientes cada uno con los mismos recursos que el nodo monolítico del escenario base. Se observa que para el nodo de exchange-api los recursos son prácticamente ociosos con apenas un uso del 6.4% de CPU y 0.8% en memoria. También se observa en los recursos del nodo de logs, un uso más constante de la memoria, esperable al streamear los datos desde disco y no conservar todos los logs en memoria.

4.4.4. Volumen operado por moneda




Figura 38. Comparativa de los resultados de volumen operado en cada moneda entre la propuesta 1 (izquierda) y el sistema base (derecha) frente a un escenario de resistencia. Se observa que la propuesta 1 obtuvo un mayor volumen total siendo este 4.31M frente al 3.59M del sistema base, es decir una mejora del 20.06 %.

4.4.5. Volumen neto operado




Figura 39. Comparativa de los resultados de volumen neto operado en cada moneda entre la propuesta 1 (izquierda) y el sistema base (derecha) frente a un escenario de resistencia. Análogamente al volumen operado, se observa que el volumen neto también es mayor en la propuesta 1 frente al sistema base en la misma proporción.

4.5. Resultados y conclusiones

La propuesta 1 demostró ser capaz de aislar la degradación producida por la consulta de logs de las operaciones de negocio del sistema, permitiendo ofrecer una mejor disponibilidad a los usuarios comunes. Por otro lado la consulta de logs sigue degradándose con el tiempo. Sin embargo, este desacoplamiento propuesto permitiría replicar el nodo de consulta para dar soporte de lectura de los logs a más usuarios, es decir, permitiendo escalabilidad horizontal.

5. PROPUESTA 2

El escenario de caos del sistema base (Sección 3.4) mostró que una única request inválida alcanza para tirar el proceso de la API y que, a partir de ese momento, el servicio queda indisponible hasta que alguien lo levante manualmente: no existe ningún mecanismo de detección ni de recuperación de fallas. Si bien la causa raíz (la falta de validación de las requests) debe corregirse, no es posible garantizar que no existan otras fallas que terminen el proceso. Por eso la propuesta 2 no apunta a evitar la falla, sino a acotar el tiempo que el servicio permanece caído cuando esta ocurre.

Para ello aplicamos las siguientes tácticas de disponibilidad:

- **Heartbeat (detección de fallas):** la API envía cada 1 segundo un datagrama UDP a cada uno de los watchdogs indicando que está viva.
- **Monitor / watchdog (detección de fallas):** se agrega un componente independiente de la API que, si no recibe un heartbeat de la API durante 3 segundos, la considera caída.
- **Restart (recuperación):** al detectar la caída, el watchdog reinicia el contenedor de la API a través de la API de Docker (montando `/var/run/docker.sock`).
- **Redundancia activa del monitor:** para que el watchdog no sea un nuevo punto único de falla, se despliegan tres instancias. Solo una de ellas (el líder) actúa sobre la API; el líder se elige mediante el algoritmo *Bully* y el resto le envía heartbeats. Si el líder deja de responder durante 3 segundos, se inicia una nueva elección.

Cabe destacar que esta propuesta se implementó sobre el sistema base y no sobre la propuesta 1, de modo que los resultados solo reflejan el efecto de estas tácticas y sean comparables contra el sistema base.




Figura 40. Diagrama Components & Connectors de la propuesta 2.

5.1. Impacto en los QA

5.1.1. Disponibilidad

Es el QA que la propuesta busca mejorar. Frente a fallas que terminan el proceso (*crash*), el tiempo de indisponibilidad pasa de ser indefinido a estar acotado por el tiempo de detección (hasta 3 segundos de timeout más 1 segundo del período de chequeo) sumado al tiempo de reinicio del contenedor. Como se verá en las pruebas de caos, esto se traduce en caídas de pocos segundos en lugar de la pérdida total del servicio.

Sin embargo, el heartbeat solo indica que el proceso está vivo y que su event loop avanza, no que responda en tiempo aceptable. Una degradación de performance como la causada por el log (Sección 3.3) no es detectada, y por lo tanto no esperamos mejoras en los escenarios de estrés y resistencia.

El valor de 3 segundos para el timeout es un tradeoff: reducirlo disminuye el tiempo de recuperación, pero aumenta el riesgo de falsos positivos. Dado que el heartbeat se envía desde el mismo event loop que atiende las requests, una operación síncrona larga (por ejemplo, serializar un log muy grande) podría retrasarlo y provocar el reinicio de una API que en realidad seguía funcionando, descartando todas las requests en curso.

5.1.2. Confiabilidad

El reinicio no resuelve la pérdida de datos. El estado se mantiene en memoria y se persiste a disco cada 1 segundo (ver Listado 5), por lo que ante un crash se pierden las operaciones realizadas desde el último guardado, además de las requests que estaban siendo procesadas. Como se utiliza `docker restart` y no se recrea el contenedor, el sistema de archivos se conserva y la API retoma desde el último estado guardado. La evidencia de esto se observa en la Figura 55, donde el tiempo de respuesta de `/log` sigue creciendo después de cada reinicio en lugar de volver a cero.

Además, la táctica no corrige la causa de la falla: la request inválida sigue tirando el proceso cada vez que llega. La propuesta mitiga el efecto, pero la validación de las requests sigue siendo necesaria.

5.1.3. Performance

El único trabajo agregado a la API es el envío de tres datagramas UDP por segundo, que consideramos despreciable frente al procesamiento de las requests. Los watchdogs corren en contenedores separados, por lo que no compiten directamente con la API, aunque sí comparten el host. En las pruebas de estrés y resistencia no se observan diferencias atribuibles a la táctica.

5.1.4. Seguridad

Para poder reiniciar la API, los watchdogs montan el socket de Docker del host. Esto les otorga control total sobre el daemon de Docker, que es equivalente a tener acceso de administrador al host. Una vulnerabilidad en el watchdog compromete todo el servidor. Además, los mensajes UDP entre la API y los watchdogs no están autenticados, por lo que cualquier proceso dentro de la red podría enviar heartbeats falsos (enmascarando una caída) o mensajes de elección.

5.1.5. Escalabilidad y modificabilidad

El nombre del contenedor supervisado (`exchange-api-1`) y la lista de watchdogs están fijos en el código. Esto impide escalar horizontalmente la API sin modificar el watchdog, y agregar o quitar watchdogs requiere modificar tanto el watchdog como la API. Por otro lado, la API no conoce al watchdog más allá del envío del heartbeat, por lo que la lógica de supervisión puede evolucionar sin cambios en el servicio.

5.1.6. Simplicidad

La arquitectura pasa de tener un único proceso de negocio a tener cuatro, e incorpora un algoritmo distribuido de elección de líder que agrega nuevos modos de falla: por ejemplo, durante una partición de red podrían existir dos líderes y ambos reiniciarían la API. Una alternativa más simple, como la política `restart: on-failure` de Docker, cubriría el caso de crash con menos componentes, pero no detectaría un proceso colgado y dejaría la recuperación atada al daemon de Docker del host.

5.2. Pruebas de carga

Las pruebas de carga comparten la misma configuración con el sistema base de tal forma que los resultados sean comparables, ver [Pruebas de carga](#).

Se pueden encontrar los resultados completos en el [Apéndice](#).

5.3. Pruebas de estrés

Las pruebas de estrés comparten la misma configuración con el sistema base de tal forma que los resultados sean comparables, ver [Pruebas de estrés](#). En este escenario el sistema se degrada por sobrecarga pero el proceso no termina, por lo que esperamos que el watchdog no intervenga.

Se pueden encontrar los resultados completos en el [Apéndice](#).

5.3.1. Disponibilidad




Figura 41. Comparativa de la disponibilidad ofrecida por la propuesta 2 (izquierda) y el sistema base (derecha) frente a un escenario de estrés. Ambos sistemas alcanzan su punto de quiebre en el mismo momento, alrededor del minuto 4:15, y presentan picos de fallas similares (1.16K frente a 1.14K por ventana). El promedio de respuestas satisfactorias es prácticamente el mismo (696 frente a 677). Como se esperaba, la táctica no mejora la disponibilidad frente a la sobrecarga.

5.3.2. Latencia




Figura 42. Comparativa de los resultados de latencia entre la propuesta 2 (izquierda) y el sistema base (derecha) frente a un escenario de estrés. Ambos se mantienen estables hasta el minuto 4 y luego se degradan con la misma forma. La propuesta 2 muestra promedios algo mayores (P50 de 1.26s frente a 1.03s), pero consideramos que la diferencia no es atribuible a la táctica, ya que el único trabajo agregado a la API es el envío de tres datagramas UDP por segundo y el uso de CPU es equivalente en ambos casos (Figura 44).



Figura 43. Comparativa de los resultados de latencia por endpoint entre la propuesta 2 (izquierda) y el sistema base (derecha) frente a un escenario de estrés. Se reproduce el mismo comportamiento del sistema base: el crecimiento del log degrada /log y arrastra a /exchange a partir del minuto 4. La propuesta 2 no aísla esta degradación, lo que es consistente con el objetivo de la táctica.

5.3.3. Uso de recursos




Figura 44. Comparativa de los resultados del uso de recursos entre la propuesta 2 (izquierda) y el sistema base (derecha) frente a un escenario de estrés. El uso de recursos de la API es equivalente en ambos casos (54.9% frente a 53.6% de CPU promedio). El uso de CPU nunca cae a cero durante la prueba, lo que indica que el watchdog no reinició la API: el heartbeat siguió llegando a pesar de la saturación.

5.3.4. Volumen operado por moneda




Figura 45. Comparativa de los resultados de volumen operado en cada moneda entre la propuesta 2 (izquierda) y el sistema base (derecha) frente a un escenario de estrés. El volumen total es prácticamente el mismo, 1.16M frente a 1.18M del sistema base (una diferencia del 1.7%).

5.3.5. Volumen neto operado




Figura 46. Comparativa de los resultados de volumen neto operado en cada moneda entre la propuesta 2 (izquierda) y el sistema base (derecha) frente a un escenario de estrés. Análogamente al volumen operado, no se observan diferencias significativas.

5.4. Pruebas de resistencia

Las pruebas de resistencia comparten la misma configuración con el sistema base de tal forma que los resultados sean comparables, ver Pruebas de resistencia. Al igual que en el escenario de estrés, la degradación se debe al crecimiento del log y no a una caída del proceso.

Se pueden encontrar los resultados completos en el Apéndice.

5.4.1. Disponibilidad




Figura 47. Comparativa de la disponibilidad ofrecida por la propuesta 2 (izquierda) y el sistema base (derecha) frente a un escenario de resistencia. Ambos sistemas comienzan a degradarse cerca del minuto 20 y hacia el minuto 35 alcanzan el mismo nivel de fallas. El promedio de respuestas satisfactorias es prácticamente el mismo (317 frente a 310). La propuesta 2 no mejora la disponibilidad frente a la degradación progresiva.

5.4.2. Latencia




Figura 48. Comparativa de los resultados de latencia entre la propuesta 2 (izquierda) y el sistema base (derecha) frente a un escenario de resistencia. Los resultados son prácticamente idénticos: P50 promedio de 1.42s frente a 1.41s y P95 de 2.46s frente a 2.47s.




Figura 49. Comparativa de los resultados de latencia por endpoint entre la propuesta 2 (izquierda) y el sistema base (derecha) frente a un escenario de resistencia. En ambos casos el tiempo de respuesta de /log crece durante toda la prueba y arrastra a /exchange, que supera el segundo a partir del minuto 20.

5.4.3. Uso de recursos




Figura 50. Comparativa de los resultados del uso de recursos entre la propuesta 2 (izquierda) y el sistema base (derecha) frente a un escenario de resistencia. El uso de CPU es equivalente (73.1 % frente a 73.2 % promedio) y alcanza la saturación a partir del minuto 20 en ambos casos. Nuevamente el uso de CPU nunca cae a cero, por lo que no hubo reinicios. Esto evidencia la principal limitación de la táctica: el sistema pasó más de 20 minutos degradado sin que el watchdog lo detectara, ya que el heartbeat solo verifica que el proceso esté vivo.

5.4.4. Volumen operado por moneda




Figura 51. Comparativa de los resultados de volumen operado en cada moneda entre la propuesta 2 (izquierda) y el sistema base (derecha) frente a un escenario de resistencia. El volumen total es prácticamente el mismo, 3.65M frente a 3.59M del sistema base (una diferencia del 1.7 %).

5.4.5. Volumen neto operado




Figura 52. Comparativa de los resultados de volumen neto operado en cada moneda entre la propuesta 2 (izquierda) y el sistema base (derecha) frente a un escenario de resistencia. Análogamente al volumen operado, no se observan diferencias significativas.

5.5. Pruebas de caos

Las pruebas de caos comparten la misma configuración con el sistema base de tal forma que los resultados sean comparables, ver [Pruebas de caos](#). Se mantiene una tasa constante de 40 requests por segundo durante 8 minutos, con una request inválida (`baseCurrency: 'XXX'`) que, al no ser válida, termina el proceso de la API. Por la aleatoriedad del escenario, en esta ejecución la request inválida apareció tres veces, cerca de los minutos 0:50, 2:35 y 5:40. Este es el escenario en el que esperamos ver el efecto de la táctica.

Se pueden encontrar los resultados completos en el [Apéndice](#).

5.5.1. Disponibilidad




Figura 53. Comparativa de la disponibilidad ofrecida por la propuesta 2 (izquierda) y el sistema base (derecha) frente a un escenario de caos. El sistema base cae en el minuto 3:15 y no vuelve a completar ninguna request durante el resto de la prueba. La propuesta 2 sufre tres caídas pero se recupera de cada una: las fallas se limitan a picos puntuales de a lo sumo 51 requests en una ventana de 10 segundos y el sistema vuelve inmediatamente a completar alrededor de 400 requests por ventana, es decir, las 40 requests por segundo generadas. Luego de cada caída se observa un pico de requests completadas (hasta 426), correspondiente a las requests acumuladas durante la caída.

5.5.2. Latencia




Figura 54. Comparativa de los resultados de latencia entre la propuesta 2 (izquierda) y el sistema base (derecha) frente a un escenario de caos. En el sistema base, luego de la caída, la latencia queda dominada por el timeout de 10 segundos. En la propuesta 2 cada caída se refleja en un pico de latencia de entre 3.2s y 4.8s (P99), consistente con el tiempo de detección configurado (3 segundos sin heartbeat más hasta 1 segundo del período de chequeo) sumado al reinicio del contenedor. Fuera de esos picos la latencia se mantiene estable, con un P50 promedio de 526ms.




Figura 55. Comparativa de los resultados de latencia por endpoint entre la propuesta 2 (izquierda) y el sistema base (derecha) frente a un escenario de caos. A diferencia del sistema base, en la propuesta 2 las métricas del servidor se siguen reportando durante toda la prueba, ya que el proceso que las emite vuelve a estar disponible. El tiempo de respuesta de /log sigue creciendo después de cada reinicio en lugar de volver a su valor inicial, lo que evidencia que el estado persistido en disco se conserva entre reinicios.

5.5.3. Uso de recursos




Figura 56. Comparativa de los resultados del uso de recursos entre la propuesta 2 (izquierda) y el sistema base (derecha) frente a un escenario de caos. En el sistema base las métricas dejan de reportarse tras la caída. En la propuesta 2 se observan tres cortes breves en los que CPU y memoria caen a cero, que coinciden con los reinicios del contenedor, y luego el reporte se retoma.

5.5.4. Volumen operado por moneda




Figura 57. Comparativa de los resultados de volumen operado en cada moneda entre la propuesta 2 (izquierda) y el sistema base (derecha) frente a un escenario de caos. El sistema base se estanca en \$298K por moneda tras la caída, mientras que la propuesta 2 alcanza \$750K por moneda, un aumento del 152 %. Los tres huecos breves en el gráfico corresponden a las caídas y el pico inmediatamente posterior a cada uno, a las operaciones acumuladas durante la caída.

5.5.5. Volumen neto operado




Figura 58. Comparativa de los resultados de volumen neto operado en cada moneda entre la propuesta 2 (izquierda) y el sistema base (derecha) frente a un escenario de caos. Análogamente al volumen operado, en la propuesta 2 el volumen neto continúa creciendo durante toda la prueba en lugar de estancarse tras la primera caída.

5.6. Resultados y conclusiones

La propuesta 2 cumple su objetivo frente a fallas que terminan el proceso: en el escenario de caos el sistema pasa de quedar indisponible de forma permanente a recuperarse en pocos segundos, y el volumen operado aumenta un 152 %. El tiempo de recuperación observado es consistente con los parámetros configurados.

Por otro lado, los escenarios de estrés y resistencia no muestran diferencias frente al sistema base. Esto es esperable, ya que el heartbeat verifica que el proceso esté vivo y no que responda en tiempo aceptable: el sistema puede estar degradado durante más de 20 minutos sin que el watchdog intervenga. Para cubrir este caso sería necesario un chequeo de salud a nivel de aplicación (por ejemplo, medir el tiempo de respuesta de un endpoint), o bien atacar la causa de la degradación como lo hace la propuesta 1. Ambas propuestas son complementarias.

Los costos de la táctica son una arquitectura más compleja, con un algoritmo distribuido y tres componentes nuevos, y un impacto negativo en la seguridad por el acceso de los watchdogs al socket de Docker. Además, la táctica no evita la pérdida de las operaciones en curso ni de las que no se llegaron a persistir, y no reemplaza la validación de las requests, que sigue siendo necesaria para eliminar la causa de la falla.

6. USO DE HERRAMIENTAS DE IA

En esta sección se detallan los usos específicos que se dieron a herramientas de inteligencia artificial durante la realización del trabajo. No todos los integrantes del grupo utilizaron estas herramientas, ni lo hicieron de la misma manera.

6.1. Conversión del informe a $\text{\LaTeX}$

El informe se redactó inicialmente en un documento de Google Docs y luego el grupo decidió migrarlo a $\text{\LaTeX}$. En el caso de algunos integrantes, que no tenían experiencia previa con $\text{\LaTeX}$, se utilizó IA para convertir al nuevo formato el contenido que ya habían escrito: estructura de secciones, figuras, tablas, listados de código y referencias cruzadas. En estos casos la herramienta se utilizó únicamente para el cambio de formato; el contenido, el análisis y las conclusiones fueron elaborados por los integrantes.

A. APÉNDICE

A.1. Resultados completos del escenario de carga sobre el sistema base




Figura 59. Escenarios del sistema base.




Figura 60. Estado de las requests del sistema base.




Figura 61. Tiempo de respuesta del sistema base.




Figura 62. Tiempo de respuesta por endpoint del sistema base. El eje tiene una escala logarítmica.




Figura 63. Estado de los recursos del sistema base. El eje izquierdo muestra el uso de CPU, el eje derecho muestra el uso de memoria.




Figura 64. Volumen operado en cada moneda en el sistema base.




Figura 65. Neto operado en cada moneda en el sistema base.

A.2. Resultados completos del escenario de estrés sobre el sistema base




Figura 66. Escenarios del sistema base.




Figura 67. Estado de las requests del sistema base.




Figura 68. Tiempo de respuesta del sistema base.




Figura 69. Tiempo de respuesta por endpoint del sistema base. El eje tiene una escala logarítmica.




Figura 70. Estado de los recursos del sistema base. El eje izquierdo muestra el uso de CPU, el eje derecho muestra el uso de memoria.




Figura 71. Volumen operado en cada moneda en el sistema base.




Figura 72. Neto operado en cada moneda en el sistema base.

A.3. Resultados completos del escenario de resistencia sobre el sistema base




Figura 73. Escenarios del sistema base.




Figura 74. Estado de las requests del sistema base.




Figura 75. Tiempo de respuesta del sistema base.




Figura 76. Tiempo de respuesta por endpoint del sistema base. El eje tiene una escala logarítmica.




Figura 77. Estado de los recursos del sistema base. El eje izquierdo muestra el uso de CPU, el eje derecho muestra el uso de memoria.




Figura 78. Volumen operado en cada moneda en el sistema base.




Figura 79. Neto operado en cada moneda en el sistema base.

A.4. Resultados completos del escenario de caos sobre el sistema base




Figura 80. Escenarios del sistema base.




Figura 81. Estado de las requests del sistema base.




Figura 82. Tiempo de respuesta del sistema base.




Figura 83. Tiempo de respuesta por endpoint del sistema base. El eje tiene una escala logarítmica.




Figura 84. Estado de los recursos del sistema base. El eje izquierdo muestra el uso de CPU, el eje derecho muestra el uso de memoria.




Figura 85. Volumen operado en cada moneda en el sistema base.




Figura 86. Neto operado en cada moneda en el sistema base.

A.5. Resultados completos del escenario de carga sobre la propuesta 1




Figura 87. Escenarios de la propuesta 1.




Figura 88. Estado de las requests de la propuesta 1.




Figura 89. Tiempo de respuesta de la propuesta 1.




Figura 90. Tiempo de respuesta por endpoint de la propuesta 1. El eje tiene una escala logarítmica.




Figura 91. Estado de los recursos del nodo de exchange de la propuesta 1. El eje izquierdo muestra el uso de CPU, el eje derecho muestra el uso de memoria.




Figura 92. Estado de los recursos del nodo de logs de la propuesta 1. El eje izquierdo muestra el uso de CPU, el eje derecho muestra el uso de memoria.




Figura 93. Volumen operado en cada moneda en la propuesta 1.




Figura 94. Neto operado en cada moneda en la propuesta 1.

A.6. Resultados completos del escenario de estrés sobre la propuesta 1




Figura 95. Escenarios de la propuesta 1.




Figura 96. Estado de las requests de la propuesta 1.




Figura 97. Tiempo de respuesta de la propuesta 1.




Figura 98. Tiempo de respuesta por endpoint de la propuesta 1. El eje tiene una escala logarítmica.




Figura 99. Estado de los recursos del nodo de exchange de la propuesta 1. El eje izquierdo muestra el uso de CPU, el eje derecho muestra el uso de memoria.




Figura 100. Estado de los recursos del nodo de logs de la propuesta 1. El eje izquierdo muestra el uso de CPU, el eje derecho muestra el uso de memoria.




Figura 101. Volumen operado en cada moneda en la propuesta 1.




Figura 102. Neto operado en cada moneda en la propuesta 1.

A.7. Resultados completos del escenario de resistencia sobre la propuesta 1




Figura 103. Escenarios de la propuesta 1.




Figura 104. Estado de las requests de la propuesta 1.




Figura 105. Tiempo de respuesta de la propuesta 1.




Figura 106. Tiempo de respuesta por endpoint de la propuesta 1. El eje tiene una escala logarítmica.




Figura 107. Estado de los recursos del nodo de exchange de la propuesta 1. El eje izquierdo muestra el uso de CPU, el eje derecho muestra el uso de memoria.




Figura 108. Estado de los recursos del nodo de logs de la propuesta 1. El eje izquierdo muestra el uso de CPU, el eje derecho muestra el uso de memoria.




Figura 109. Volumen operado en cada moneda en la propuesta 1.




Figura 110. Neto operado en cada moneda en la propuesta 1.

A.8. Resultados completos del escenario de carga sobre la propuesta 2




Figura 111. Escenarios de la propuesta 2.




Figura 112. Estado de las requests de la propuesta 2.




Figura 113. Tiempo de respuesta de la propuesta 2.




Figura 114. Tiempo de respuesta por endpoint de la propuesta 2. El eje tiene una escala logarítmica.




Figura 115. Estado de los recursos de la propuesta 2. El eje izquierdo muestra el uso de CPU, el eje derecho muestra el uso de memoria.




Figura 116. Volumen operado en cada moneda en la propuesta 2.




Figura 117. Neto operado en cada moneda en la propuesta 2.

A.9. Resultados completos del escenario de estrés sobre la propuesta 2




Figura 118. Escenarios de la propuesta 2.




Figura 119. Estado de las requests de la propuesta 2.




Figura 120. Tiempo de respuesta de la propuesta 2.




Figura 121. Tiempo de respuesta por endpoint de la propuesta 2. El eje tiene una escala logarítmica.




Figura 122. Estado de los recursos de la propuesta 2. El eje izquierdo muestra el uso de CPU, el eje derecho muestra el uso de memoria.




Figura 123. Volumen operado en cada moneda en la propuesta 2.




Figura 124. Neto operado en cada moneda en la propuesta 2.

A.10. Resultados completos del escenario de resistencia sobre la propuesta 2




Figura 125. Escenarios de la propuesta 2.




Figura 126. Estado de las requests de la propuesta 2.



Figura 127. Tiempo de respuesta de la propuesta 2.




Figura 128. Tiempo de respuesta por endpoint de la propuesta 2. El eje tiene una escala logarítmica.




Figura 129. Estado de los recursos de la propuesta 2. El eje izquierdo muestra el uso de CPU, el eje derecho muestra el uso de memoria.




Figura 130. Volumen operado en cada moneda en la propuesta 2.




Figura 131. Neto operado en cada moneda en la propuesta 2.

A.11. Resultados completos del escenario de caos sobre la propuesta 2




Figura 132. Escenarios de la propuesta 2.




Figura 133. Estado de las requests de la propuesta 2.




Figura 134. Tiempo de respuesta de la propuesta 2.




Figura 135. Tiempo de respuesta por endpoint de la propuesta 2. El eje tiene una escala logarítmica.




Figura 136. Estado de los recursos de la propuesta 2. El eje izquierdo muestra el uso de CPU, el eje derecho muestra el uso de memoria.




Figura 137. Volumen operado en cada moneda en la propuesta 2.




Figura 138. Neto operado en cada moneda en la propuesta 2.